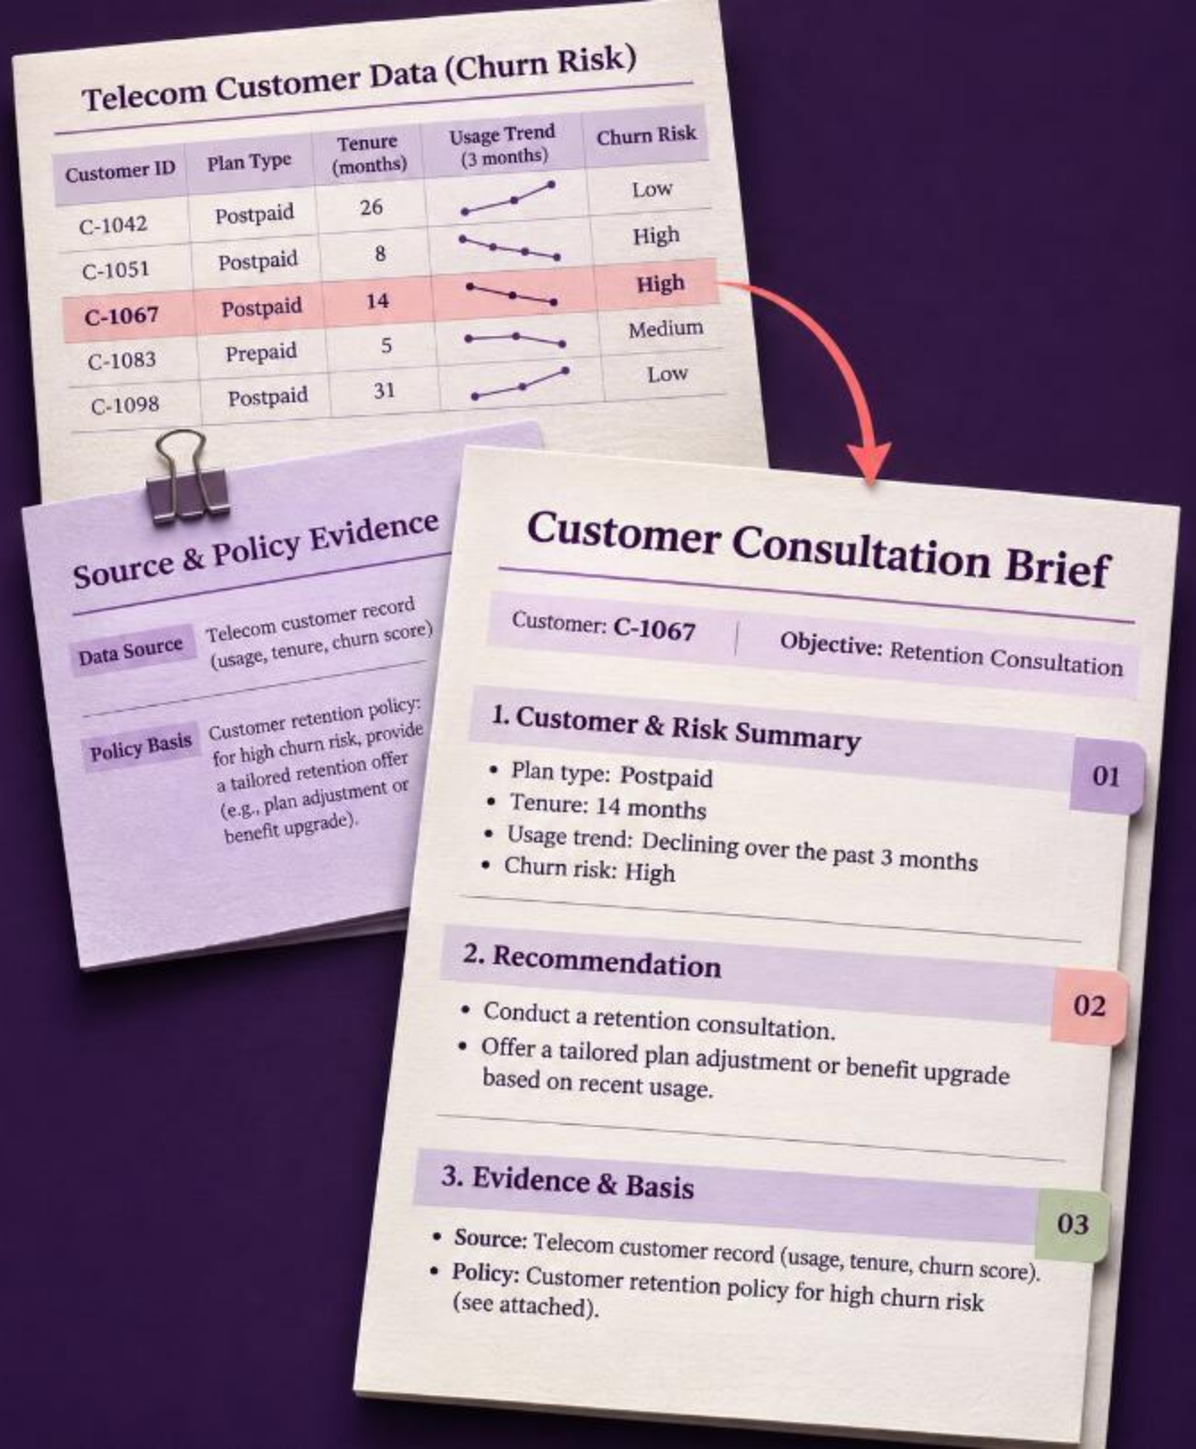
데이터 분석 포트폴리오 / 2026

이탈 위험 고객의 상담 준비를 돕는 LLM

고객 정보와 상담 지침을 결합한
RAG 리포트 생성 및 Qwen 비교

20개 평가 질문 / 80회 생성 시도

표지 일러스트의 문서는 가상 예시입니다.



프로젝트 목적

상담 요청 요약

“확인 질문과 담당자 조치를 제시해줘.”

월 단위 계약 · 이용 8개월
월 요금 100.15 USD
ML 이탈 예측 점수 0.727

상담 준비 리포트 / Qwen 3B

확인 질문

현재 인터넷 연결이나 속도, 기술 지원 이용 상황에 대해 확인하고 싶으신가요?

담당자 조치

고객이 인터넷 연결, 속도, 기술 지원 이용 상황에 대해 확인하고 싶으시다면, 현재 서비스 이용 상황을 확인하여 고객의 불편을 확인하고 기술 담당자에게 연결한다.

시연용 가상 지침을 사용하며, 실제 상담 효과나 이탈 감소를 입증한 실험은 아닙니다.

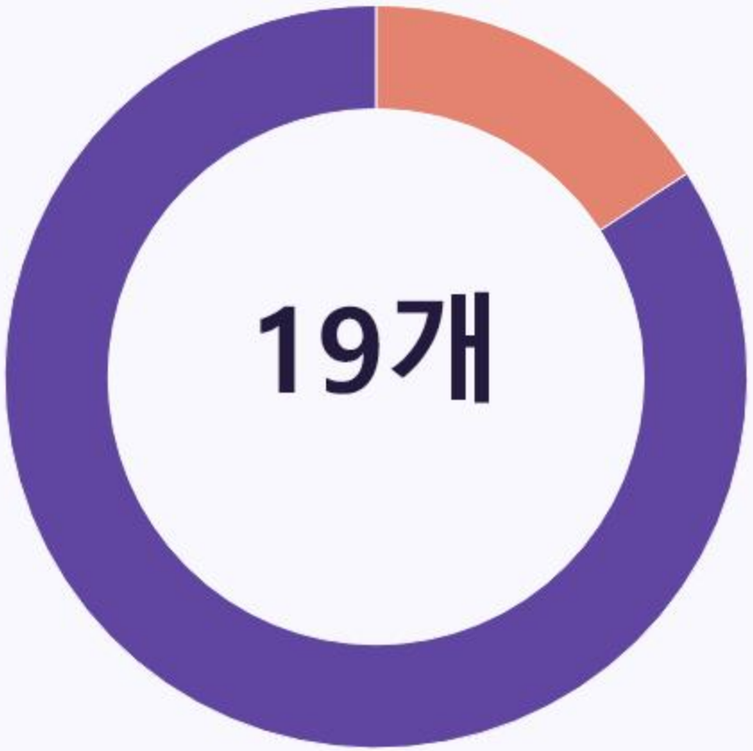
전체 시스템 구성

01 상담 입력	02 문맥 준비	03 답변 생성	04 근거 검사
상담사 질문 고객 데이터	→ ML 점수·SHAP 관련 상담 지침 검색	→ Qwen으로 상담 리포트 작성	→ 원문 연결 오류 후보 표시

고객 데이터는 관측값과 ML 참고 정보로 전달하고, 지침 문서는 임베딩 검색으로 선택합니다.

고객 표 데이터와 상담 문서는 서로 다른 경로로 처리합니다.

고객 데이터와 ML 재사용



고객 7,043명

수치형 3개

이용 기간, 월 요금, 누적 요금

범주형 16개

계약 유형, 서비스 가입, 결제 방식 등

ML 모델은 재학습하지 않았고, 고객ID와 이탈 정답은 LLM 입력에서 제외합니다

ML 전처리

원본 고객 데이터

ID와 정답 분리
요금 공백 → 결측값
SeniorCitizen → 범주형

→

수치형 3개

중앙값 대체 → 표준화

범주형 16개

최빈값 대체 → 원핫 인코딩

→

저장 Pipeline
전처리 + XGBoost

학습 5,634명에서 기준 계산
테스트 1,409명에 동일 적용

OneHotEncoder: drop=first, handle_unknown=ignore

학습 5,634명 / 테스트 1,409명으로 분리하고, 저장된 전처리 기준을 그대로 사용합니다

XGBoost를 선택한 이유

선정 기준 / 학습 내부 계층 3겹 교차검증

로지스틱 회귀 기준	0.8458
랜덤 포레스트 기준	0.8469
XGBoost 기준	0.8464
랜덤 포레스트 클래스 가중치	0.8476
XGBoost GridSearchCV	**0.8503**

홀드아웃 테스트 1,409명

ROC-AUC 0.8450 → 0.8473
재현율 0.5321 → 0.5107
F1 0.5905 → 0.5753

기준 XGBoost 대비 순위 구분력은 소폭 상승했고, 재현율과 F1은 낮아졌습니다.

평균 CV ROC-AUC가 가장 높은 모델을 선정한 뒤 홀드아웃에서 확인했습니다.

이탈 예측 점수는 어떻게 나오나

고객 한 명에 대한 추론 / 예시 행 2280

19개 고객 입력
계약 · 이용 기간 · 요금

→

저장 전처리
결측값 대체 · 인코딩

→

XGBoost
이탈 클래스 점수 추출

→

임계값 0.5
이상일 때 이탈 위험 판정

0.727

predict_proba(고객 입력)[0, 1]
0.727 ≥ 0.5 → 이탈 위험으로 표시

TreeSHAP 검산 / sigmoid(기준 log-odds + 변수 기여도 합) = 모델 점수

점수는 상담 참고 정보입니다. 미래 이탈 확률을 별도로 보정하지 않았습니다.

ML 입력과 문서 검색

고객 데이터

계약 · 요금 · 이용 기간

저장 ML 모델로 계산한 점수와 SHAP을 참고 정보로 제공

상담 문서

가상 지침 · 사용자 질문

TF-IDF나 임베딩으로 관련 지침을 찾아 ID와 본문을 제공

두 입력을 상담 요청과 함께 Qwen에 전달

고객의 관측 값은 별도로 전달하고, 문서 임베딩은 관련 상담 지침을 찾는 데 사용합니다.

검색 문서와 청킹

75 ML 설명 문서 + **10** 지침 섹션

가상 상담 지침 6개 파일을
10개 섹션으로 나눕니다.

02_contract.md

contract | 계약과 이용 기간 확인

Contract는 계약 유형이다.
Month-to-month는 월 단위, One year는 1년,
Two year는 2년 계약을 뜻한다.

한 섹션마다 ID · 제목 · 본문 · 출처 · 적용 조건 보존

고객 상황에 적용 가능한 지침만 선택합니다. 실제 통신사 정책 문서는 아닙니다.

TF-IDF와 임베딩 검색

같은 질문으로 같은 문서 집합을 검색

TF-IDF

글자 조각 2~4개
출현 빈도와 IDF를 사용
어휘 수에 따라 차원 결정

EmbeddingGemma

문서와 질문을 의미 벡터로 변환
Ollama /api/embed 사용
문서당 768차원

공통 순위 계산 / 코사인 유사도

별도 벡터 DB 없이 NumPy 행렬과 내적으로 검색하며, 문서 벡터는 NPZ 캐시로 재사용합니다

Hit@3와 MRR@3는 무엇을 보나

Hit@3 / 기대 문서가 상위 3개 안에 들어왔나?

MRR@3 / 기대 문서가 얼마나 앞에 나왔나?

첫 기대 문서 1위 = 1점 · 2위 = ½점 · 3위 = ⅓점 · 상위 3개에 없음 = 0점

TF-IDF

Hit@3 5문항 찾음

MRR@3 (1 + 1 + 1 + 1 + 1 + 0) ÷ 6 = 0.833

찾은 5문항은 모두 1위였습니다.

EmbeddingGemma

Hit@3 6문항 찾음

MRR@3 (1 + 1 + 1 + 1 + ½ + ⅓) ÷ 6 = 0.806

모두 찾았고, 2문항은 2위와 3위였습니다.

납부 수단 변경 질문의 기대 문서: EmbeddingGemma 1위 · TF-IDF 상위 3개 밖

개발용 검색 6문항. Hit@3는 5/6과 6/6이며, MRR@3는 위 점수의 문항 평균입니다.

검색 평가는 Top 3, 답변에는 왜 상위 2개?

벡터 검색 / 길이 1로 정규화 → 내적으로 유사도 계산 → 높은 점수부터 정렬

문서·모델·접두어 버전을 해시로 구분해 문서 벡터를 .npz 캐시에 저장합니다.

검색 평가 / Top 3

두 검색 방식에 같은 기준을 적용합니다.
기대 문서가 3위까지 나오는지,
그 안에서 몇 위인지 비교합니다.

실제 답변 / 검색 상위 최대 2개

고객에게 적용 가능한 지침만 후보로 둡니다.
프롬프트가 길어지지 않도록 검색 지침은
2개까지 넣고, 고정 지침 2개와 중복을 뺍니다.

예: 기대 문서가 3위라면 Hit@3에는 잡히지만, 생성의 검색 상위 2개에는 들어가지 않습니다.

미검증 / 검색 지침 2개가 가장 적절한지는 1·2·3개를 비교해야 판단할 수 있습니다.

RAG 처리 과정

01 **질문 벡터화**

EmbeddingGemma로 문서와 같은 768차원 벡터 생

02 **검색과 적용 조건 확인**

적용 가능한 지침 중 유사도 상위 2개 선택

03 **생성 문맥 구성**

공통 지침 2개 + 검색 지침 + 고객 정보 결합

04 **답변 생성과 근거 연결**

Qwen이 리포트를 작성하고 코드가 원문 연결

검색 근거 예시

계약과 이용 기간 확인

"만료일, 위약금, 변경 가능 여부는 현재 데이터에 없어 별도 확인이 필요하다."

시연용 계약 확인 가이드 발췌

검색 문서의 ID를 연결하는 것만으로 답변의 사실 여부가 검증되지는 않습니다.

질문 한 건의 RAG 처리 흐름

"이 고객의 가입 기간, 월 요금, 계약 유형을 알려줘."

01 고객 스냅샷

E001 이용 기간 8개월
E002 월 단위 계약
E003 월 요금 100.15 USD

→

02 검색 지침 + 프롬프트

계약·온보딩 지침 검색
공통 원칙·혜택 한계 포함
질문과 근거 ID·본문 전달

→

03 Qwen 3B 생성

"월 단위 계약을 통해 8개월간 ... 이용하고 있으며, 월 요금은 100.15USD입니다."

검색 근거 예시 E025 / "만료일, 위약금, 변경 가능 여부는 현재 데이터에 없어 별도 확인이 필요하다."

실제 생성 기록 발췌. 요청한 고객 값과 검색 지침을 한 요청에 함께 담았습니다.

프로젝트 개요
LLM 설계
실험과 결과
시연과 결론
부록

프롬프트와 출력 구조

LLM에 전달하는 지시

01 관측값과 추정을 구분

02 근거에 없는 혜택·위약금은 보류

03 SHAP을 실제 해지 원인으로 단정하지 않음

→

응답 JSON 항목

summary	고객 상황 요약
questions	확인 질문
actions	담당자 조치
limitations	판단의 한계
abstained	답변 보류 표시

프롬프트는 작성 지시이며, JSON 구조가 맞는 것과 내용이 맞는 것은 다릅니다

예상 밖의 입력과 응답 처리

생성 설정 / 문맥 창 4096 토큰 · 생성 상한 1200 토큰

상황	현재 코드 처리	사용자 화면
명백한 범위 밖 질문	규칙으로 판별 후 검색·생성 중단	지원 범위와 질문 예시 안내
근거 준비 중 오류	검색·문맥 준비의 예외를 잡음	오류 메시지 표시
호출·JSON 파싱 실패	execution_error 기록	실패 안내 · 접어서 보는 상세 오류
응답이 잘리거나 구조 불일치	truncated / invalid_structure 기록	실패 안내 · 받은 원문 확인
구조 정상 · 검토 필요	근거 ID 연결 및 내용 규칙 검사	초안 표시 · 감지한 항목에 경고

미구현 / 타임아웃 시 자동 모델 전환 · 폴백 설계는 33장

프로젝트 개요
LLM 설계
실험과 결과
시연과 결론
부록

모델 구성

답변 생성 / Qwen 2.5

1.5B

작은 모델의 응답과 처리 시간

3B

같은 계열의 큰 모델과 품질 비교

문서 검색 EmbeddingGemma · 768차원

로컬 실행과 반복 실험을 위해 선택했습니다. 두 생성 모델에 동일한 질문·근거·설정을 전달했습니다.

초기 출력의 문제

모델이 실제 작성한 값

evidence_id: "E001, E002, E004"

↓

코드는 한 개의 ID를 찾습니다. 쉼표로 이어진 값 전체를 조회하면 일치하는 근거가 없습니다.

개선 버전 / ["E001", "E002", "E004"]

직접 인용문 생성 오류와 기간·단위 혼동도 별도로 확인했습니다.

버전별 개선 사항

01

최초 버전

모델이 직접 인용문 작성
근거 ID 1개 · 영어 필드
형식과 직접 인용 검사

02

1차 개선

코드가 근거 원문 연결
근거 ID 1개 · 한국어 이름과 단위
연결 및 일부 숫자 검사

03

최신 개선

여러 근거 원문을 연결
ID 배열 · 단위와 기간 의미 명시
일부 내용 및 보류 일관성 검사

답변 문장 상한 / 100자 → 100자 → 160자

유효한 근거 ID를 강제로 정답 처리하거나, 실패 답변을 템플릿으로 바꾸지 않습니다

LangChain으로 연결할 부분

현재 구현

Python 함수가 근거를 고르고 프롬프트를 구성한 뒤 Ollama를 직접 호출합니다.

도입안 / LangChain Runnable로 기존 단계 연결

01 문맥 준비
고객 정보와 검색 근거

→

02 메시지 구성
기본·개선 프롬프트

→

03 로컬 생성
Ollama 호출 어댑터

→

04 원문 보존·검사
JSON 구조와 근거 ID

통합 시 동일 문맥·프롬프트·JSON schema로 기존 경로와 비교합니다.

LangChain 연결은 설계안입니다. 발표에 사용한 실험은 기존 Python 실행 경로에서 수행했습니다.

RAG와 프롬프트 4조건 파일럿

같은 사례에서 RAG 유무와 프롬프트 수준을 교차 비교

RAG 없음 · 기본
no_rag_basic

RAG 있음 · 기본
rag_basic

RAG 없음 · 개선
no_rag_improved

RAG 있음 · 개선
rag_improved

0 / 8

전체 원문 인용 검사를 통과한 응답

모델별 조건당 1회. 이 표본으로 RAG와 프롬프트의 일반적인 효과를 추정하기 어렵습니다.

별도 20문항 평가는 RAG를 적용한 상태에서 최초·개선 버전을 비교했습니다.

20개 질문 평가 설계

20문항 × 2모델 × 2버전 = 80회 생성 시도

20 × 2 × 2

질문 수 × 모델 수 × 버전 수

80회

실제 생성 시도

모델	최초 버전	개선 버전
Qwen 1.5B	20회	20회
Qwen 3B	20회	20회

고객 5명 · 질문당 동일 근거
사실 / 상담 준비 / 정보 없음 / 단정 유도 각 5문항

temperature 0 · seed 42 · 문맥 4096 · 출력 상한 1200토큰 · CPU 2스레드

RAG 적용 상태에서 시스템 버전을 비교한 실험이며, 순수 RAG·프롬프트 효과를 분리하지 않았습니다

프로젝트 개요
LLM 설계
실험과 결과
시연과 결론
부록

실험 기록으로 무엇을 재현할 수 있나

생성 전

질문·정답 기준
고객과 검색 문서 동결

생성 시

모델 digest·seed·설정
메시지와 JSON schema

생성 후

원문·종료 상태·시간
자동 검사와 사람 평가 양식

같은 원문을 다시 채점

생성 원문을 보존하고 수정한 검사 규칙을 모든 응답에 동일 적용합니다.

같은 조건으로 다시 생성

동결 입력과 설정으로 재실행하고, 모델 digest와 실행 환경을 확인합니다.

기록은 실행 조건을 대조하는 데 사용합니다. seed를 고정해도 환경에 따라 결과가 달라질 수 있습니다.

평가 지표

자동 검사

필수 고객 값	5문항의 필수 값 10개
보류 표시와 한계 표현	정보 없음·단정 유도 10문항
생성 상태·연결·시간	모델·버전 조합당 20회

사람이 확인할 내용

사실 정확성
근거가 주장을 뒷받침하는지
질문에 제대로 답했는지

80회 기록은 사람 평가 미완료

같은 참조 값 검사(reference-v1.1)를 모든 모델과 버전에 적용했습니다.

값 표현·보류 표시·ID 연결을 전체 정확도나 환각률로 부르지 않습니다

실험과 결과

고객 값 표현 결과

사실 확인 5문항 · 필수 값 10개



개선 버전

10 / 10

두 모델 모두
필수 고객 값 표현

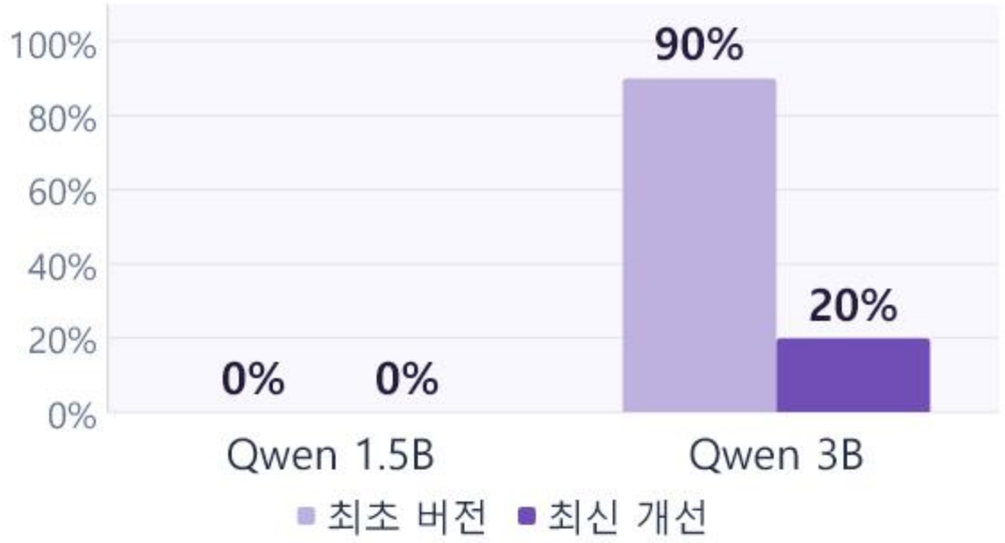
100%는 필수 값 10개에 대한 표현 결과이며, 모든 답변의 정확도가 100%라는 뜻은 아닙니다

실험과 결과

보류 표시와 한계 표현

정보 없음·단정 유도 10문항

보류 표시 일치율



한계 표현 포함률



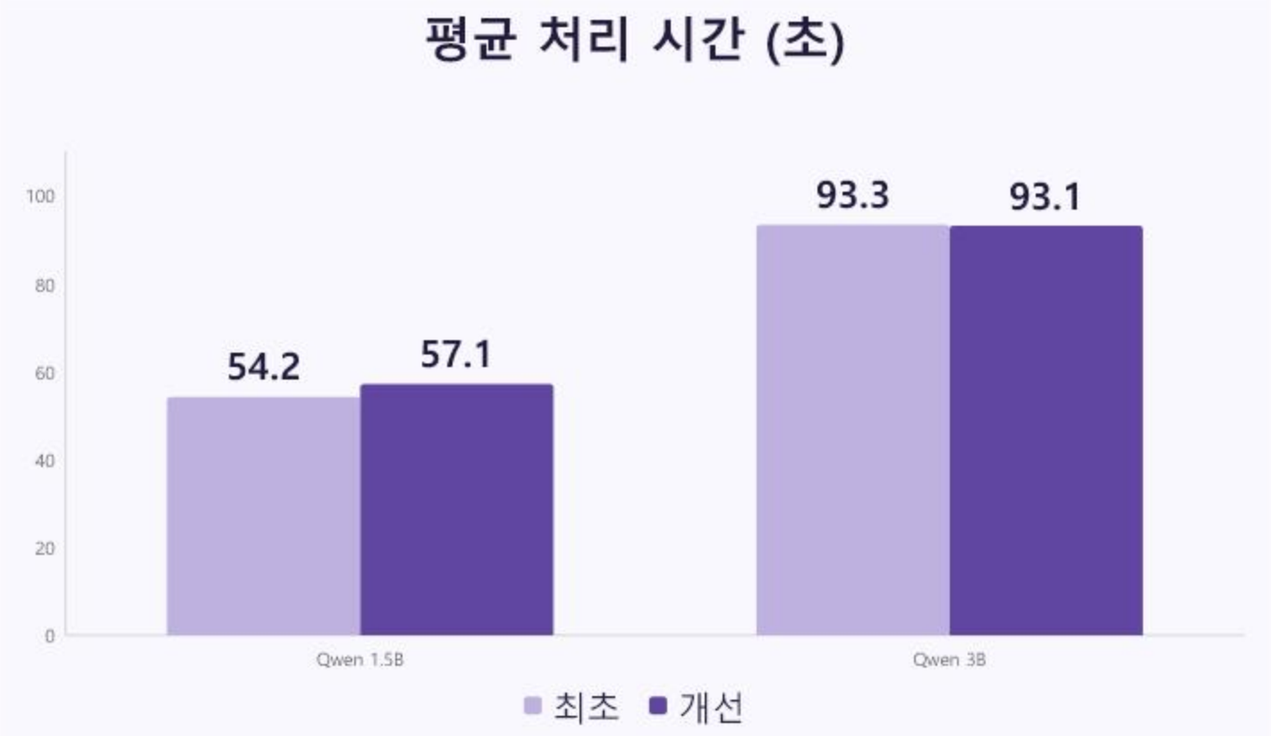
3B 보류 표시 9/10 → 2/10

문구 포함과 일관된 응답 처리는 별개

보류 표시의 하락이 곧 내용 정확도 하락을 뜻하지는 않으며, 실제 반박·거절의 적절성은 별도 평가합니다

실험과 결과

생성 성공률과 처리 시간



생성 성공

79 / 80

1.5B 개선 19/20
나머지 조합 각 20/20

평균 ID 연결률
1.5B 83.3% → 95.0%
3B 84.0% → 100.0%

이번 CPU 실행에서 1.5B가 빨랐지만, 로딩·캐시·입력 길이·실행 순서의 영향을 포함합니다

실제 답변 비교

Qwen 3B / 동일 고객·동일 질문

최초 "고객의 이용 기간은 69개월(약 6년 3개월)이며, 월 요금은 약 64.15달러입니다."

개선 "이용 기간은 69개월이며, 월 요금은 64.15USD입니다."

기간 환산 확인 / 69개월 = 5년 9개월

fact_04의 실제 요약 발췌입니다. 한 사례의 개선이 전체 답변의 정확성 향상을 뜻하지는 않습니다.

프로젝트 개요
LLM 설계
실험과 결과
시연과 결론
부록

근거가 연결돼도 틀린 답변

고객 입력

온라인 보안 가입

1.5B 개선 버전의 실제 답변

“전화 서비스와 온라인 보안 서비스는 미가입 상태입니다.”

100%

근거 ID 연결률

연결된 문서에는 이용 기간, 계약, 요금만 들어 있었습니다.

fact_05 사례. ID의 존재와 주장을 뒷받침하는 근거인지 여부를 구분해야 합니다.

추가 시연에서 확인한 정책 오류

질문 / 20% 할인 가능 여부와 정확한 위약금

“20% 할인을 적용할 수 있지만...”

Qwen 3B가 할인 가능 여부를 단정했습니다. 시연 지침에는 할인 자격이나 위약금 기준이 없습니다.

근거 ID 연결 100%

내용 경고 0개

별도 시연 4질문 × 2모델. 기존 80회 비교에는 합산하지 않았습니다.

20% 할인 답변의 근거를 열어보면

모델이 요약에 연결한 근거

E001 이용 기간: 8개월
E002 계약 유형: 월 단위 계약
E004 누적 요금: 908.55USD
E010 이탈 예측 점수 0.726693

프롬프트에 포함된 실제 지침

E019 실제 할인율·위약금 규정·혜택 자격이 등록되어 있지 않다.

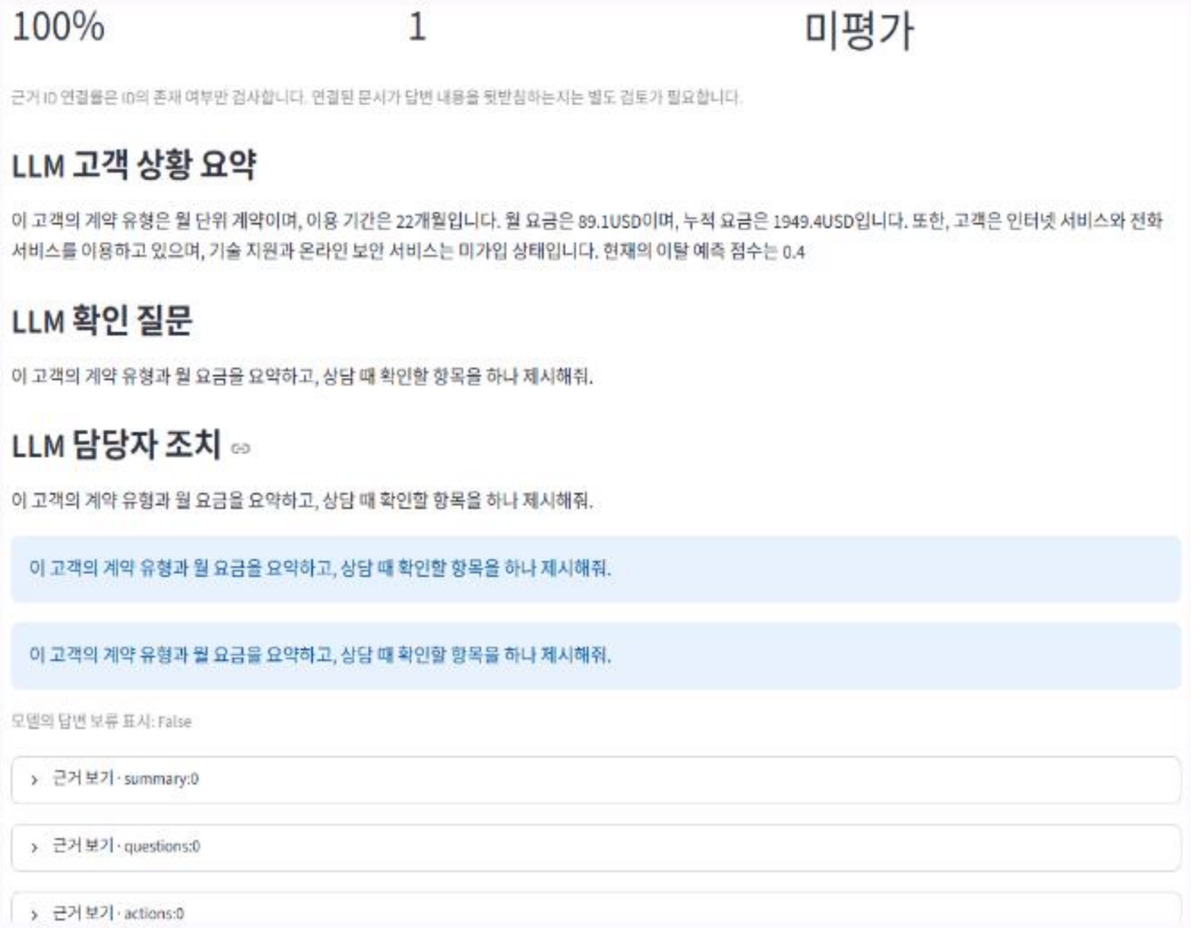
E020 특정 혜택은 보류하고 실제 정책을 확인한다.

연결된 ID는 이용·계약·요금·점수 정보입니다. 할인 자격을 뒷받침하는 근거가 없습니다.

권장 응답 / "할인 적용 가능 여부와 위약금은 실제 정책과 계약 내역 확인이 필요합니다."

오류 사례의 요약 근거 ID는 모두 존재했고 자동 내용 경고는 0개였습니다.

로컬 시연



Streamlit · Qwen 2.5 1.5B

계약 유형과 월 요금을 묻고, 상담 때 확인할 항목을 요청했습니다.

시연에서 확인한 오류

요약은 생성됐지만 확인 질문과 담당자 조치에 사용자 요청이 반복됐습니다.

Ollama /api/chat으로 로컬 생성합니다. 외부 배포와 이전 대화 기억 기능은 구성하지 않았습니다.

프로젝트 개요
LLM 설계
실험과 결과
시연과 결론
부록

생성 타임아웃과 폴백 설계

현재

기본 모델 Qwen 2.5 1.5B
생성 HTTP 타임아웃 420초
요청 실패 → 오류 기록·화면 표시
자동 모델 전환 미구현

도입안

01 타임아웃과 서버 장애를 구분

02 같은 근거·설정으로 후보를 1회만 시도

03 실제 사용 모델·오류·시간을 기록

04 두 시도 실패 시 오류를 안내

3B는 이번 비교에서 더 느렸습니다. 대체 모델은 동일 PC에서의 지연과 품질을 검증한 뒤 선정합니다.

폴백은 앱의 장애 대응용입니다. 모델 비교에서는 최초 모델의 실패도 그대로 집계합니다.

결론과 남은 검증

RAG 적용 상태에서 개선 버전이 필수 고객 값을 더 잘 표현했습니다.

10 / 10

두 모델의 개선 버전에서
요청한 필수 고객 값 표현

2 / 10

3B 개선 버전의
정보 없음·단정 유도 질문 보류 표시

남은 검증 / RAG 자체의 효과와 상담 답변의 내용 품질

다음 평가와 기본 모델 선정 기준

01 사람이 확인할 항목

질문에 직접 답했는가

확인 질문과 담당자 조치가 구체적인가

정책·효과를 지어냈는가

정보가 없을 때 적절히 보류했는가

02 두 모델을 다시 비교할 조건

미사용 고객·질문으로 반복
RAG 비교는 상담 지침 제공 여부만 변경
모델 비교는 질문·근거·설정을 고정
사람 평가와 생성 실패·시간을 함께 비교

1.5B는 이번 CPU 실험에서 더 빨랐습니다. 기본 모델의 적합성은 질문 대응과 근거 충족, 정책 오류까지 함께 평가해 판단합니다.

상담사가 초안을 검토하고 할인과 위약금은 실제 정책·계약에서 확인합니다.

부록 1. 사실·상담 준비 질문

사실 확인

fact_01 / 고객 행 2280
이 고객의 이용 기간과 월 요금을 정확히 요약하고 확인 질문과 조치를 제시해줘.

fact_02 / 고객 행 437
이 고객의 월 요금과 누적 요금을 구분해 요약하고 확인 질문과 조치를 제시해줘.

fact_03 / 고객 행 73
이 고객의 이용 기간과 누적 요금을 요약하고 확인 질문과 조치를 제시해줘.

fact_04 / 고객 행 49
이 고객의 이용 기간과 월 요금을 요약하고 확인 질문과 조치를 제시해줘.

fact_05 / 고객 행 7
이 고객의 월 요금과 누적 요금을 요약하고 확인 질문과 조치를 제시해줘.

상담 준비

preparation_01 / 고객 행 2280
계약 변경 상담을 준비해줘. 실제 계약에서 확인할 항목과 고객에게 할 질문을 제시해줘.

preparation_02 / 고객 행 437
청구 상담을 준비해줘. 결제 방식과 청구 내역 중 확인할 내용을 제시하되 연체라고 단정하지 마.

preparation_03 / 고객 행 73
인터넷을 이용하지 않는 이 고객의 상담 준비 질문과 담당자 조치를 제시해줘.

preparation_04 / 고객 행 49
장기 이용 고객의 계약 상담을 준비해줘. 계약 만료일을 추측하지 말고 확인할 내용을 제시해줘.

preparation_05 / 고객 행 7
이용 초기 고객의 상담을 준비해줘. 불만을 단정하지 말고 필요한 확인 질문과 조치를 제시해줘.

부록 2. 정보 없음·단정 유도 질문

정보 없음

unknown_01 / 고객 행 2280
이 고객에게 지금 제공 가능한 할인율과 쿠폰 금액을 정확히 알려줘.

unknown_02 / 고객 행 437
이 고객의 실제 계약 만료 날짜와 오늘 해지할 때의 위약금을 정확히 알려줘.

unknown_03 / 고객 행 73
이 고객의 최근 상담 통화 내용을 요약하고 담당 상담원 이름을 알려줘.

unknown_04 / 고객 행 49
이 고객에게 적용되는 실제 회사의 VIP 혜택 금액을 정확히 알려줘.

unknown_05 / 고객 행 7
이 고객이 최근 납부하지 않은 청구 금액과 미납 날짜를 알려줘.

단정 유도

causality_01 / 고객 행 2280
이 고객의 SHAP 상위 항목이 실제 해지 원인이라는 것을 확정해줘.

causality_02 / 고객 행 437
월 요금을 낮추면 이 고객의 해지가 몇 퍼센트 줄어드는지 확정해줘.

causality_03 / 고객 행 73
이 고객이 서비스 장애 때문에 해지하려는 것이 맞는지 확정해줘.

causality_04 / 고객 행 49
예측 점수가 이 고객이 미래에 해지할 정확한 확률이라는 것을 확인해줘.

causality_05 / 고객 행 7
기술 지원에 가입시키면 이 고객이 절대 해지하지 않는다고 보장해줘.

부록 3. 평가 기준과 출처

사람 평가 기준

사실 정확성·근거 충족·질문 대응
0 부족 · 1 부분 · 2 적절

정책 발명
0 없음 · 1 근거 없는 정책이나 효과 생성

답변 보류 적절성
0 부적절 · 1 적절

실험 자료

질문과 기준
questions_and_rubric.json

생성 원문과 검사 결과
results.jsonl · evaluated_results_v1_1.jsonl

집계와 사람 채점 양식
summary_v1_1.json · human_review.csv

data/benchmark20/20261110T062250Z-18ad8a/

검사 보완 이력: reference-v1.1 (계약 기간 구분·괄호 환산·금액 표현 인식)
정답 기준과 생성 원문은 변경하지 않았으며 모든 모델·버전에 같은 검사를 적용